TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP

KHOA ĐIỆN TỬ

BÀI TIỂU LUẬN MÔN KĨ THUẬT LẬP TRÌNH NÂNG CAO

NGÀNH : KỸ THUẬT MÁY TÍNH

HỆ : ĐẠI HỌC CHÍNH QUY

ĐỀ TÀI: ỨNG DỤNG THUẬT TOÁN KMP VÀ BOYER–MOORE TRONG TÌM KIẾM VĂN BẢN TIẾNG VIỆT

THÁI NGUYÊN – 2026

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP

KHOA ĐIỆN TỬ

BÀI TIỂU LUẬN MÔN KĨ THUẬT LẬP TRÌNH NÂNG CAO

BỘ MÔN : CÔNG NGHỆ THÔNG TIN

ĐỀ TÀI: ỨNG DỤNG THUẬT TOÁN KMP VÀ BOYER–MOORE TRONG TÌM KIẾM VĂN BẢN TIẾNG VIỆT

GIÁO VIÊN HƯỚNG DẪN : TS. Nghiên Văn Tính

SINH VIÊN : Lý Văn Cường (1)

Nguyễn Đức Dương (2)

MSSV: K225480106100 (1)

K225480106093 (2)

LỚP: K58KTP

THÁI NGUYÊN - 2026

TRƯỜNG ĐHKTCN **CỘNG HOÀ XÃ HỘI CHỦ NGHĨA VIỆT NAM**

KHOA ĐIỆN TỬ ***Độc lập - Tự do - Hạnh phúc***

NHIỆM VỤ THIẾT KẾ BÀI TIỂU LUẬN MÔN KĨ THUẬT LẬP TRÌNH NÂNG CAO

Sinh viên: Lý Văn Cường Mssv: K225480106100

Nguyễn Đức Dương Mssv: K225480106093

Lớp: K58KTP **Khoá:** 2022 - 2027

Bộ môn: Công Nghệ Thông Tin

Giáo viên hướng dẫn: Ts. Nghiêm Văn Tính

Tên đề tài: Ứng dụng thuật toán kmp và boyer–moore trong tìm kiếm văn bản tiếng việt

1. Nội dung các phần thuyết minh báo cáo
   - Giới thiệu bài toán và mục tiêu.
   - Cơ sở lý thuyết và thuật toán.
   - Cài đặt và kết quả thực nghiệm.
   - Đánh giá và kết luận.

3. Các sản phẩm, kết quả :
   - Mã nguồn chương trình.
   - Bộ ảnh đầu vào và ảnh kết quả.
   - File báo cáo bài tập lớn.
   - Thuyết minh báo cáo, Slide

4. Ngày giao nhiệm vụ:

5. Ngày hoàn thành nhiệm vụ:

BCN KHOA	TRƯỞNG BỘ MÔN	GIÁO VIÊN HƯỚNG DẪN
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*	*(Ký và ghi rõ họ tên)*

TRƯỜNG ĐHKTCN	**CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM**
KHOA ĐIỆN TỬ	***Độc lập – Tự do – Hạnh phúc***

PHIẾU GHI ĐIỂM

Sinh viên: Lý Văn Cường Mssv: K225480106100

Nguyễn Đức Dương Mssv: K225480106093

Lớp: K58KTP **Khoá:** 2022 - 2027

Bộ môn: Công Nghệ Thông Tin

Giáo viên hướng dẫn: Ts. Nghiêm Văn Tính

Đề tài: Ứng dụng thuật toán kmp và boyer–moore trong tìm kiếm văn bản tiếng việt

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

……

……

……

……

Lý Văn Cường Xếp Loại:..... Điểm:.....…

Nguyễn Đức Dương Xếp Loại:..... Điểm:.....

Thái Nguyên, ngày….tháng…..năm 2026

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

MỤC LỤC

CHƯƠNG I. TỔNG QUAN VỀ MÔN HỌC VÀ ĐỀ TÀI 7
1.1. Bài toán tìm kiếm chuỗi trong văn bản 7
1.1.1. Giới thiệu chung về môn học 7
1.1.2. Mục tiêu của môn học 7
1.1.3. Nội dung chính của môn học 7
1.1.4. Phương pháp học tập và thực hành 8
1.1.5. Vai trò và ý nghĩa của môn học 8
1.2. Tổng quan về đề tài 8
1.2.1. Lý do chọn đề tài 8
1.2.2. Mục tiêu của đề tài 9
1.2.3. Phạm vi và đối tượng nghiên cứu 9
1.2.4. Phương pháp nghiên cứu 9
1.2.5. Ý nghĩa khoa học và thực tiễn 9
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT 10
2.1. Bài toán tìm kiếm chuỗi trong văn bản 10
2.1.1. Khái niệm bài toán tìm kiếm chuỗi 10
2.1.2. Phương pháp tìm kiếm chuỗi cơ bản 10
2.1.3. Đặc thù của văn bản tiếng Việt 11
2.2. Thuật toán Knuth–Morris–Pratt (KMP) 11
2.2.1. Giới thiệu thuật toán KMP 11
2.2.2. Ý tưởng của thuật toán KMP 11
2.2.3. Mảng LPS (Longest Prefix Suffix) 11
2.2.4. Quy trình thực hiện thuật toán KMP 12
2.2.5. Độ phức tạp của thuật toán KMP 12
2.3. Thuật toán Boyer–Moore 12
2.3.1. Giới thiệu thuật toán Boyer–Moore 12
2.3.2. Ý tưởng của thuật toán Boyer–Moore 13

2.3.3. Luật ký tự xấu (Bad Character Rule) 13
2.3.4. Luật hậu tố tốt (Good Suffix Rule) 13
2.3.5. Độ phức tạp của thuật toán Boyer–Moore 13
2.4. So sánh thuật toán KMP và Boyer–Moore 14
CHƯƠNG 3: XÂY DỰNG CHƯƠNG TRÌNH TÌM KIẾM VĂN BẢN TIẾNG VIỆT BẰNG THUẬT TOÁN KMP VÀ BOYER–MOORE 15
3.1. Phân tích bài toán 15
3.1.1. Mô tả bài toán 15
3.1.2. Yêu cầu của chương trình 15
3.1.3. Hướng tiếp cận 15
3.2. Mô hình tổng quát của chương trình 16
3.3. Xây dựng thuật toán tìm kiếm 16
3.3.1. Thuật toán KMP 16
3.3.2. Thuật toán Boyer–Moore 16
3.4. Cài đặt chương trình 17
3.4.1. Ngôn ngữ và công cụ sử dụng 17
3.4.2. Demo chương trình: 17
CHƯƠNG 4: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 19
4.1. Kết luận 19
4.2. Ưu điểm và hạn chế của đề tài 20
4.2.1. Ưu điểm 20
4.2.2. Hạn chế 20
4.3. Hướng phát triển đề tài 20
TÀI LIỆU THAM KHẢO 22

LỜI CAM ĐOAN

Chúng em xin cam đoan rằng báo cáo với đề tài "***Ứng dụng thuật toán KMP và Boyer–Moore trong tìm kiếm văn bản tiếng Việt***", được thực hiện trong khuôn khổ môn học Kỹ thuật Lập trình Nâng cao, là công trình nghiên cứu do chính chúng em trực tiếp thực hiện dưới sự hướng dẫn của giảng viên. Toàn bộ nội dung nghiên cứu, phương pháp thực hiện, kết quả phân tích và đánh giá trong báo cáo đều được xây dựng dựa trên quá trình học tập, tìm hiểu và nghiên cứu nghiêm túc của chúng em. Các số liệu, ví dụ minh họa và kết quả trình bày trong báo cáo là trung thực, có nguồn gốc rõ ràng và phản ánh đúng quá trình thực nghiệm. Chúng em xin cam đoan rằng báo cáo này chưa từng được công bố, sao chép hay sử dụng để nộp cho bất kỳ học phần, đề tài hay công trình nghiên cứu nào khác. Nếu có bất kỳ sai sót hoặc vi phạm nào liên quan đến nội dung cam đoan, chúng em xin hoàn toàn chịu trách nhiệm.

LỜI NÓI ĐẦU

Trong lĩnh vực khoa học máy tính, đặc biệt là xử lý chuỗi và tìm kiếm văn bản, bài toán tìm kiếm mẫu đóng vai trò quan trọng và có tính ứng dụng cao trong nhiều hệ thống như công cụ tìm kiếm, xử lý văn bản, kiểm tra đạo văn và phân tích dữ liệu ngôn ngữ. Việc xác định nhanh chóng và chính xác vị trí xuất hiện của một chuỗi con trong văn bản lớn là yêu cầu thiết yếu nhằm nâng cao hiệu năng và độ tin cậy của các hệ thống phần mềm.

Tuy nhiên, đối với các văn bản có kích thước lớn hoặc ngôn ngữ có đặc thù riêng như tiếng Việt, việc tìm kiếm bằng các phương pháp đơn giản thường gặp nhiều hạn chế về tốc độ và hiệu quả. Điều này đòi hỏi phải áp dụng các thuật toán tìm kiếm chuỗi tối ưu nhằm giảm thiểu số phép so sánh và cải thiện thời gian xử lý.

Xuất phát từ nhu cầu đó, chúng em đã lựa chọn đề tài "Ứng dụng thuật toán KMP và Boyer–Moore trong tìm kiếm văn bản tiếng Việt". Đề tài tập trung nghiên cứu nguyên lý hoạt động, ưu điểm và hạn chế của hai thuật toán KMP và Boyer–Moore, đồng thời tiến hành cài đặt và so sánh hiệu quả của chúng trong bài toán tìm kiếm văn bản tiếng Việt.

Báo cáo này trình bày từ cơ sở lý thuyết của các thuật toán tìm kiếm chuỗi, quy trình xây dựng chương trình cài đặt cho đến các kết quả thực nghiệm và đánh giá hiệu năng. Thông qua đề tài, chúng em mong muốn làm rõ vai trò của các thuật toán tối ưu trong kỹ thuật lập trình nâng cao, đồng thời góp phần nâng cao hiệu quả xử lý văn bản tiếng Việt trong các ứng dụng thực tế.

CHƯƠNG I. TỔNG QUAN VỀ MÔN HỌC VÀ ĐỀ TÀI

1.1. Bài toán tìm kiếm chuỗi trong văn bản

1.1.1. Giới thiệu chung về môn học

Trong bối cảnh công nghệ thông tin phát triển mạnh mẽ, các hệ thống phần mềm ngày càng có yêu cầu cao về tốc độ xử lý, độ chính xác và khả năng tối ưu. Do đó, việc nắm vững các kỹ thuật lập trình cơ bản là chưa đủ, sinh viên cần được trang bị thêm kiến thức về các phương pháp lập trình nâng cao và các thuật toán hiệu quả.

Môn học **Kỹ thuật lập trình nâng cao** được xây dựng nhằm giúp sinh viên tiếp cận các tư tưởng thiết kế thuật toán hiện đại, rèn luyện tư duy logic và khả năng phân tích bài toán một cách khoa học. Thông qua môn học, sinh viên không chỉ hiểu cách cài đặt chương trình mà còn biết đánh giá, lựa chọn và tối ưu thuật toán phù hợp với từng bài toán cụ thể.

1.1.2. Mục tiêu của môn học

- Môn học Kỹ thuật lập trình nâng cao hướng tới các mục tiêu chính sau:

- Trang bị cho sinh viên kiến thức nền tảng về thuật toán và cấu trúc dữ liệu nâng cao.
- Rèn luyện tư duy thuật toán, khả năng phân tích và giải quyết các bài toán phức tạp.
- Giúp sinh viên biết cách đánh giá độ phức tạp và hiệu năng của chương trình.
- Nâng cao kỹ năng lập trình và khả năng áp dụng thuật toán vào các bài toán thực tế.

1.1.3. Nội dung chính của môn học

- Nội dung môn học tập trung vào các kỹ thuật và phương pháp thiết kế thuật toán quan trọng, bao gồm:

- Phân tích và mô hình hóa bài toán bằng thuật toán.
- Phân tích độ phức tạp thời gian và bộ nhớ của thuật toán.
- Các kỹ thuật thiết kế thuật toán phổ biến:

    1. Chia để trị (Divide and Conquer).
    2. Tham lam (Greedy).
    3. Quy hoạch động (Dynamic Programming).
    4. Quay lui (Backtracking).
    5. Các thuật toán tìm kiếm và xử lý chuỗi.

- Ứng dụng các kỹ thuật trên để giải quyết các bài toán trong thực tế như tìm kiếm, sắp xếp, xử lý văn bản và dữ liệu.

1.1.4. Phương pháp học tập và thực hành

- Bên cạnh phần lý thuyết, môn học chú trọng đến thực hành lập trình. Sinh viên được yêu cầu:

- Cài đặt các thuật toán bằng ngôn ngữ lập trình cụ thể (C/C++, Java hoặc Python).
- Thực hiện bài tập lớn nhằm áp dụng thuật toán vào bài toán thực tế.
- Phân tích, đánh giá và tối ưu chương trình đã xây dựng.

- Thông qua đó, sinh viên có thể hiểu rõ hơn bản chất của thuật toán và nâng cao năng lực lập trình.

1.1.5. Vai trò và ý nghĩa của môn học

- Môn Kỹ thuật lập trình nâng cao có vai trò quan trọng trong chương trình đào tạo ngành Công nghệ thông tin và Kỹ thuật máy tính:

- Là nền tảng cho các môn học chuyên ngành như trí tuệ nhân tạo, học máy, xử lý ngôn ngữ tự nhiên và phân tích dữ liệu.
- Giúp sinh viên hình thành tư duy giải quyết vấn đề có hệ thống và hiệu quả.
- Góp phần nâng cao chất lượng nguồn nhân lực trong lĩnh vực công nghệ thông tin.

1.2. Tổng quan về đề tài

1.2.1. Lý do chọn đề tài

Trong thời đại số hóa, dữ liệu văn bản xuất hiện ngày càng nhiều trong các hệ thống thông tin, công cụ tìm kiếm, mạng xã hội và các ứng dụng xử lý ngôn ngữ tự nhiên. Một trong những bài toán quan trọng trong xử lý văn bản là **bài toán tìm kiếm chuỗi**, tức là xác định vị trí xuất hiện của một chuỗi mẫu trong một văn bản lớn.

Đối với văn bản tiếng Việt, việc tìm kiếm chuỗi gặp thêm nhiều khó khăn do đặc thù ngôn ngữ như sử dụng bảng mã Unicode, ký tự có dấu và độ dài ký tự không cố định. Nếu sử dụng các phương pháp tìm kiếm đơn giản, hiệu năng sẽ không cao, đặc biệt với dữ liệu lớn.

Thuật toán **Knuth–Morris–Pratt (KMP)** và **Boyer–Moore** là hai thuật toán tìm kiếm chuỗi nổi tiếng, giúp giảm số phép so sánh và tăng tốc độ tìm kiếm. Việc nghiên cứu và ứng dụng hai thuật toán này vào bài toán tìm kiếm văn bản tiếng Việt không chỉ mang ý nghĩa học thuật mà còn có giá trị thực tiễn cao. Chính vì vậy, đề tài **"Ứng dụng thuật toán KMP và Boyer–Moore trong tìm kiếm văn bản tiếng Việt"** được lựa chọn để nghiên cứu và thực hiện.

1.2.2. Mục tiêu của đề tài

- Mục tiêu chính của đề tài là nghiên cứu và ứng dụng các thuật toán tìm kiếm chuỗi hiệu quả vào bài toán tìm kiếm văn bản tiếng Việt. Cụ thể:

- Nghiên cứu nguyên lý hoạt động của thuật toán KMP và Boyer–Moore.
- Phân tích bài toán tìm kiếm chuỗi trong văn bản tiếng Việt.
- Cài đặt chương trình tìm kiếm văn bản bằng hai thuật toán trên.
- So sánh hiệu quả của các thuật toán về thời gian và số phép so sánh.
- Đánh giá khả năng ứng dụng của các thuật toán trong thực tế.

1.2.3. Phạm vi và đối tượng nghiên cứu

- Phạm vi nghiên cứu:

- Bài toán tìm kiếm chuỗi trong văn bản tiếng Việt.
- Áp dụng thuật toán KMP và Boyer–Moore.
- Cài đặt chương trình bằng ngôn ngữ lập trình Python.
- Không nghiên cứu các thuật toán tìm kiếm chuỗi nâng cao khác.

- Đối tượng nghiên cứu:

- Thuật toán KMP và Boyer–Moore.
- Văn bản tiếng Việt sử dụng bảng mã Unicode.
- Quy trình xây dựng và đánh giá chương trình tìm kiếm văn bản.

1.2.4. Phương pháp nghiên cứu

- Nghiên cứu tài liệu, giáo trình và các nguồn tham khảo về thuật toán tìm kiếm chuỗi.
- Phân tích lý thuyết kết hợp với cài đặt thực nghiệm.
- So sánh và đánh giá kết quả thực nghiệm của các thuật toán.
- Tham khảo ý kiến của giảng viên hướng dẫn và các tài liệu học thuật.

1.2.5. Ý nghĩa khoa học và thực tiễn

- Ý nghĩa khoa học:

- Giúp củng cố kiến thức về thuật toán xử lý chuỗi.
- Làm rõ ưu điểm và hạn chế của thuật toán KMP và Boyer–Moore.
- Là tài liệu tham khảo cho sinh viên trong học tập và nghiên cứu.

- Ý nghĩa thực tiễn:

- Có thể áp dụng vào các hệ thống tìm kiếm văn bản, xử lý dữ liệu tiếng Việt.

- Là nền tảng để phát triển các ứng dụng xử lý ngôn ngữ tự nhiên trong tương lai.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Bài toán tìm kiếm chuỗi trong văn bản

2.1.1. Khái niệm bài toán tìm kiếm chuỗi

Bài toán tìm kiếm chuỗi (String Matching) là bài toán xác định vị trí xuất hiện của một chuỗi con, gọi là **chuỗi mẫu** (Pattern), trong một chuỗi lớn hơn, gọi là **chuỗi văn bản** (Text).

Giả sử:

- Chuỗi văn bản TTT có độ dài nnn
- Chuỗi mẫu PPP có độ dài mmm

- Nhiệm vụ của bài toán là tìm tất cả các vị trí iii sao cho:

T[i..i+m−1]=PT[i..i+m-1] = PT[i..i+m−1]=P

- Bài toán tìm kiếm chuỗi là nền tảng của nhiều ứng dụng quan trọng như:

- Công cụ tìm kiếm văn bản
- Trình soạn thảo và tìm kiếm từ khóa
- Xử lý ngôn ngữ tự nhiên
- Kiểm tra đạo văn và phân tích dữ liệu văn bản

2.1.2. Phương pháp tìm kiếm chuỗi cơ bản

Phương pháp tìm kiếm chuỗi đơn giản nhất là **tìm kiếm tuần tự (Brute-force)**. Thuật toán này tiến hành so sánh chuỗi mẫu với từng vị trí trong chuỗi văn bản, từ trái sang phải.

- Đặc điểm của phương pháp:

- Dễ cài đặt
- Không yêu cầu cấu trúc dữ liệu phức tạp
- Tuy nhiên, số phép so sánh lớn

- Độ phức tạp thời gian của phương pháp này trong trường hợp xấu nhất là:

O(n×m)O(n \times m)O(n×m)

- Với văn bản dài hoặc số lượng tìm kiếm lớn, phương pháp này không hiệu quả, từ đó dẫn đến nhu cầu sử dụng các thuật toán tối ưu hơn.

2.1.3. Đặc thù của văn bản tiếng Việt

- Văn bản tiếng Việt có những đặc điểm riêng biệt ảnh hưởng đến quá trình tìm kiếm chuỗi:

- Sử dụng bảng mã Unicode (UTF-8)
- Ký tự có dấu và dấu phụ
- Một ký tự có thể được biểu diễn bằng nhiều byte

- Do đó, khi áp dụng các thuật toán tìm kiếm chuỗi vào văn bản tiếng Việt, cần đảm bảo:

- So sánh theo đơn vị ký tự, không theo byte
- Xử lý chính xác các ký tự Unicode
- Đảm bảo tính đúng đắn và hiệu quả khi tìm kiếm

2.2. Thuật toán Knuth–Morris–Pratt (KMP)

2.2.1. Giới thiệu thuật toán KMP

Thuật toán Knuth–Morris–Pratt (KMP) là một thuật toán tìm kiếm chuỗi hiệu quả, được đề xuất bởi Donald Knuth, Vaughan Pratt và James H. Morris. Thuật toán giúp giảm số phép so sánh dư thừa bằng cách tận dụng thông tin từ các lần so sánh trước đó.

Khác với phương pháp tìm kiếm tuần tự, KMP không quay ngược lại chuỗi văn bản khi xảy ra sai khác, từ đó giúp cải thiện đáng kể hiệu năng.

2.2.2. Ý tưởng của thuật toán KMP

- Ý tưởng cốt lõi của thuật toán KMP là:

- Khi xảy ra sai khác giữa chuỗi mẫu và chuỗi văn bản, không cần so sánh lại các ký tự đã biết là trùng khớp
- Sử dụng một mảng phụ trợ để xác định vị trí dịch chuyển hợp lý của chuỗi mẫu

- Thuật toán sử dụng mảng **LPS (Longest Prefix Suffix)** để ghi lại thông tin về các tiền tố và hậu tố trùng nhau trong chuỗi mẫu.

2.2.3. Mảng LPS (Longest Prefix Suffix)

- Mảng LPS tại vị trí iii lưu độ dài của tiền tố dài nhất của chuỗi mẫu cũng là hậu tố của đoạn P[0..i]P[0..i]P[0..i].

- Ví dụ, với chuỗi mẫu:

```
P = ABABCABAB
```

- Mảng LPS tương ứng:

```
LPS = [0, 0, 1, 2, 0, 1, 2, 3, 4]
```

- Mảng LPS giúp thuật toán xác định được số ký tự có thể bỏ qua khi xảy ra sai khác, từ đó giảm số phép so sánh không cần thiết.

2.2.4. Quy trình thực hiện thuật toán KMP

- Thuật toán KMP gồm hai bước chính:

1. Xây dựng mảng LPS cho chuỗi mẫu
2. Thực hiện tìm kiếm chuỗi mẫu trong văn bản dựa trên mảng LPS

- Trong quá trình tìm kiếm, nếu có sự không khớp:

- Con trỏ của chuỗi mẫu được dịch chuyển dựa trên giá trị LPS
- Con trỏ của chuỗi văn bản không cần quay lại vị trí trước đó

2.2.5. Độ phức tạp của thuật toán KMP

- Thời gian xây dựng mảng LPS: O(m)
- Thời gian tìm kiếm chuỗi: O(n)

- Tổng độ phức tạp thời gian:

O(n+m)O(n + m)O(n+m)

- Thuật toán KMP có hiệu năng ổn định và phù hợp với các bài toán tìm kiếm chuỗi trong văn bản lớn.

2.3. Thuật toán Boyer–Moore

2.3.1. Giới thiệu thuật toán Boyer–Moore

Thuật toán Boyer–Moore là một trong những thuật toán tìm kiếm chuỗi hiệu quả nhất trong thực tế. Thuật toán này thực hiện so sánh chuỗi mẫu với chuỗi văn bản theo hướng từ phải sang trái.

Nhờ sử dụng các luật dịch chuyển thông minh, Boyer–Moore có thể bỏ qua nhiều vị trí không cần thiết trong chuỗi văn bản.

2.3.2. Ý tưởng của thuật toán Boyer–Moore

- Ý tưởng chính của thuật toán Boyer–Moore là:

- So sánh chuỗi mẫu từ ký tự cuối cùng
- Khi xảy ra sai khác, dịch chuyển chuỗi mẫu một khoảng lớn thay vì chỉ một ký tự

- Thuật toán sử dụng hai luật dịch chuyển chính:

- Luật ký tự xấu (Bad Character Rule)
- Luật hậu tố tốt (Good Suffix Rule)

2.3.3. Luật ký tự xấu (Bad Character Rule)

- Khi xảy ra sai khác tại một ký tự trong quá trình so sánh:

- Nếu ký tự đó xuất hiện trong chuỗi mẫu, dịch chuyển chuỗi mẫu sao cho ký tự gây lỗi trùng với lần xuất hiện cuối cùng của nó trong chuỗi mẫu
- Nếu ký tự không tồn tại trong chuỗi mẫu, dịch chuyển toàn bộ chiều dài chuỗi mẫu

- Luật này giúp loại bỏ nhiều phép so sánh không cần thiết.

2.3.4. Luật hậu tố tốt (Good Suffix Rule)

- Nếu một hậu tố của chuỗi mẫu đã được so sánh và trùng khớp:

- Thuật toán dịch chuyển chuỗi mẫu sao cho hậu tố này xuất hiện lại trong chuỗi mẫu
- Hoặc dịch sao cho tiền tố dài nhất của chuỗi mẫu trùng với hậu tố đã khớp

- Luật hậu tố tốt giúp tăng hiệu quả tìm kiếm trong nhiều trường hợp.

2.3.5. Độ phức tạp của thuật toán Boyer–Moore

- Trường hợp trung bình: rất nhanh, thường nhanh hơn KMP
- Trường hợp xấu nhất: O(n×m)O(n \times m)O(n×m)

Tuy nhiên, trong thực tế, Boyer–Moore được đánh giá là một trong những thuật toán tìm kiếm chuỗi nhanh nhất.

2.4. So sánh thuật toán KMP và Boyer–Moore

Tiêu chí	KMP	Boyer–Moore
Hướng so sánh	Trái → phải	Phải → trái
Độ phức tạp	O(n + m)	Rất nhanh trong thực tế
Tính ổn định	Cao	Phụ thuộc dữ liệu
Phù hợp	Văn bản lớn	Tìm kiếm thực tế

CHƯƠNG 3: XÂY DỰNG CHƯƠNG TRÌNH TÌM KIẾM VĂN BẢN TIẾNG VIỆT BẰNG THUẬT TOÁN KMP VÀ BOYER–MOORE

3.1. Phân tích bài toán

3.1.1. Mô tả bài toán

Bài toán đặt ra là xây dựng một chương trình cho phép tìm kiếm một chuỗi mẫu trong một văn bản tiếng Việt cho trước. Văn bản có thể có độ dài lớn và chứa các ký tự Unicode có dấu. Chương trình cần xác định chính xác các vị trí xuất hiện của chuỗi mẫu trong văn bản.

- Cụ thể:

- **Đầu vào**:

  1. Chuỗi văn bản tiếng Việt TTT
  2. Chuỗi mẫu cần tìm PPP

- **Đầu ra**:

  1. Danh sách các vị trí xuất hiện của chuỗi mẫu trong văn bản
  2. Thời gian thực hiện tìm kiếm của từng thuật toán

3.1.2. Yêu cầu của chương trình

- Chương trình cần thỏa mãn các yêu cầu sau:

- Tìm kiếm chính xác chuỗi mẫu trong văn bản tiếng Việt có dấu.
- Áp dụng hai thuật toán KMP và Boyer–Moore.
- So sánh hiệu quả của hai thuật toán.
- Giao diện đơn giản, dễ sử dụng.
- Dễ dàng mở rộng và cải tiến trong tương lai.

3.1.3. Hướng tiếp cận

- Để giải quyết bài toán, chương trình được xây dựng theo các bước:

- Nhập văn bản tiếng Việt và chuỗi mẫu cần tìm.
- Tiến hành tìm kiếm chuỗi mẫu bằng thuật toán KMP.
- Tiến hành tìm kiếm chuỗi mẫu bằng thuật toán Boyer–Moore.

- Ghi nhận kết quả tìm kiếm và thời gian thực hiện.
- So sánh và đánh giá hiệu quả của hai thuật toán.

3.2. Mô hình tổng quát của chương trình

- Chương trình được chia thành các khối chức năng chính như sau:

- Khối nhập dữ liệu (văn bản và chuỗi mẫu).
- Khối xử lý tìm kiếm bằng thuật toán KMP.
- Khối xử lý tìm kiếm bằng thuật toán Boyer–Moore.
- Khối hiển thị kết quả và đánh giá.

- Mô hình tổng quát của chương trình được thể hiện qua sơ đồ khối sau:

Văn bản + Chuỗi mẫu → Thuật toán KMP / Boyer–Moore → Kết quả tìm kiếm → Đánh giá

3.3. Xây dựng thuật toán tìm kiếm

3.3.1. Thuật toán KMP

- Ý tưởng áp dụng

Thuật toán KMP được sử dụng để tìm kiếm chuỗi mẫu trong văn bản bằng cách tránh so sánh lại các ký tự đã biết là trùng khớp. Điều này đặc biệt hiệu quả khi xử lý văn bản dài.

Các bước thực hiện

- Bước 1: Xây dựng mảng LPS cho chuỗi mẫu.
- Bước 2: So sánh chuỗi mẫu với chuỗi văn bản từ trái sang phải.
- Bước 3: Khi xảy ra sai khác, dịch chuyển chuỗi mẫu dựa trên mảng LPS.
- Bước 4: Ghi nhận vị trí khi tìm thấy chuỗi mẫu.

3.3.2. Thuật toán Boyer–Moore

- Ý tưởng áp dụng

Thuật toán Boyer–Moore so sánh chuỗi mẫu từ phải sang trái và sử dụng các luật dịch chuyển để bỏ qua nhiều vị trí không cần thiết trong văn bản, giúp tăng tốc độ tìm kiếm.

- Các bước thực hiện

- Bước 1: Xây dựng bảng ký tự xấu cho chuỗi mẫu.
- Bước 2: So sánh chuỗi mẫu với chuỗi văn bản từ phải sang trái.
- Bước 3: Khi xảy ra sai khác, dịch chuyển chuỗi mẫu dựa trên luật ký tự xấu.
- Bước 4: Ghi nhận vị trí khi tìm thấy chuỗi mẫu.

3.4. Cài đặt chương trình

3.4.1. Ngôn ngữ và công cụ sử dụng

- Chương trình được cài đặt bằng:

- Ngôn ngữ lập trình: **Python**
- Môi trường phát triển: Python 3.x
- Hỗ trợ xử lý Unicode, phù hợp với văn bản tiếng Việt

3.4.2. Demo chương trình:

- Giao diện hệ thống:

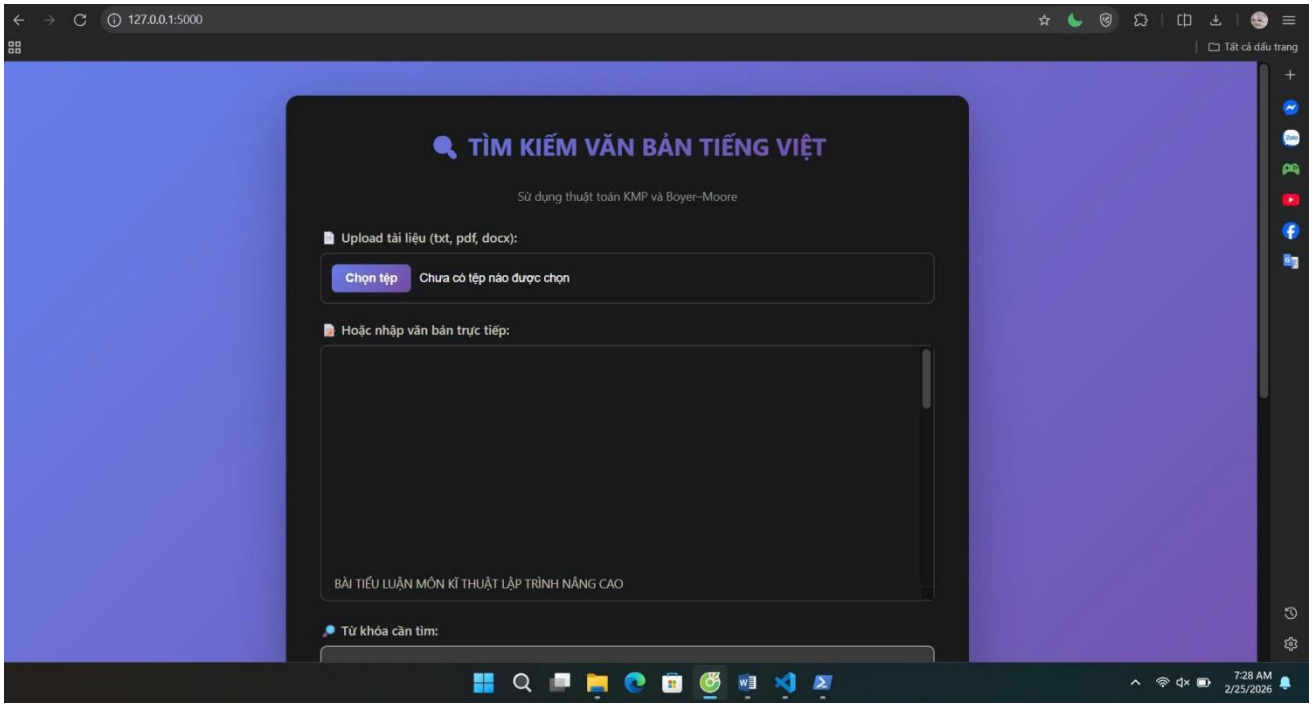

- Kết quả thực thi:

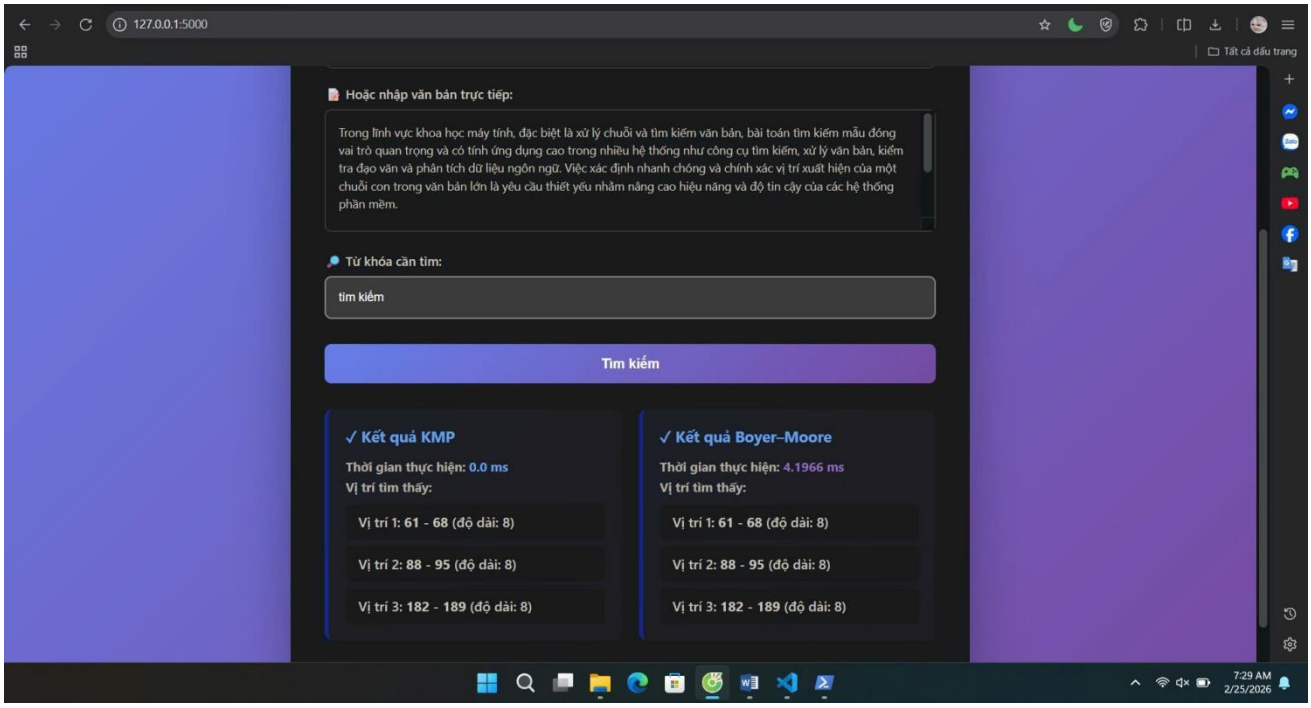

CHƯƠNG 4: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.1. Kết luận

Sau quá trình nghiên cứu lý thuyết và thực hiện cài đặt thực nghiệm đề tài "Ứng dụng thuật toán KMP và Boyer–Moore trong tìm kiếm văn bản tiếng Việt", nhóm/em đã đạt được những kết quả sau:

Về mặt lý thuyết:

Nắm vững cơ chế hoạt động của các thuật toán tìm kiếm chuỗi hiện đại. Hiểu rõ cách mảng LPS trong KMP giúp tận dụng các tiền tố lặp lại và cách các quy tắc "Ký tự xấu", "Hậu tố tốt" trong Boyer–Moore giúp bỏ qua các phép so sánh dư thừa.

Phân tích được những thách thức đặc thù của tiếng Việt khi xử lý trên máy tính như bảng mã Unicode, các tổ hợp dấu và độ dài byte thay đổi.

Về mặt thực nghiệm:

Xây dựng thành công chương trình tìm kiếm bằng ngôn ngữ **Python**, đảm bảo tính chính xác khi tìm kiếm các cụm từ có dấu phức tạp.

Thông qua thực nghiệm, đã minh chứng được hiệu quả vượt trội của KMP và Boyer–Moore so với thuật toán Brute-force truyền thống, đặc biệt là khi kích thước văn bản (n) và độ dài mẫu (m) tăng lên.

Boyer–Moore cho thấy tốc độ xử lý rất nhanh trong các trường hợp thực tế nhờ khả năng "nhảy" bước dài trên văn bản.

4.2. Ưu điểm và hạn chế của đề tài

4.2.1. Ưu điểm

Tính chính xác: Chương trình xử lý tốt các ký tự Unicode tiếng Việt, không xảy ra lỗi khi gặp các ký tự có dấu phụ.

Hiệu năng: Tốc độ tìm kiếm nhanh, đáp ứng được nhu cầu xử lý các tệp văn bản có dung lượng từ vừa đến lớn.

Giao diện: Trực quan, hiển thị rõ ràng vị trí tìm thấy (index) và thời gian thực thi để người dùng dễ dàng đánh giá.

4.2.2. Hạn chế

Chuẩn hóa dữ liệu: Hiện tại thuật toán vẫn phụ thuộc vào việc văn bản đầu vào phải cùng chuẩn Unicode (NFC hoặc NFD). Nếu văn bản trộn lẫn các chuẩn này, kết quả tìm kiếm có thể bị sót.

Tính năng: Chương trình mới chỉ dừng lại ở việc tìm kiếm chuỗi khớp chính xác 100%, chưa hỗ trợ tìm kiếm không dấu hoặc tìm kiếm gần đúng (fuzzy search).

Dung lượng cực lớn: Với các file dữ liệu khổng lồ (hàng GB), việc nạp toàn bộ vào bộ nhớ để tìm kiếm vẫn còn gặp hạn chế về tài nguyên máy tính.

4.3. Hướng phát triển đề tài

Trong tương lai, để ứng dụng này trở nên hoàn thiện và có giá trị thực tiễn cao hơn, đề tài có thể phát triển theo các hướng sau:

Hỗ trợ tìm kiếm linh hoạt: Tích hợp tính năng tìm kiếm không phân biệt chữ hoa/chữ thường và đặc biệt là tìm kiếm tiếng Việt không dấu (người dùng gõ "tieng viet" vẫn ra kết quả "tiếng việt").

Xử lý tìm kiếm gần đúng (Fuzzy String Matching): Sử dụng khoảng cách Levenshtein hoặc thuật toán Bitap để tìm kiếm các từ gần đúng, hỗ trợ người dùng khi họ gõ sai chính tả.

Tối ưu hóa cho Big Data: Áp dụng kỹ thuật lập trình đa luồng (Multithreading) hoặc cơ chế đọc file theo từng phân đoạn (Chunking) để xử lý các tệp văn bản cực lớn mà không làm treo hệ thống.

Tích hợp vào ứng dụng thực tế: Phát triển chương trình thành một thư viện (API) hoặc một tiện ích mở rộng trên trình duyệt để hỗ trợ tìm kiếm nhanh trong các tài liệu văn bản tiếng Việt trực tuyến.

TÀI LIỆU THAM KHẢO

Sách Giáo trình: *Giải thuật và Lập trình* của Thầy Lê Minh Hoàng (Đại học Sư phạm Hà Nội) – Đây là "cuốn sách gối đầu giường" về thuật toán tại Việt Nam.

Tài liệu quốc tế: *Introduction to Algorithms* (CLRS) – Cuốn sách kinh điển thế giới về cấu trúc dữ liệu và giải thuật.

Giáo trình Giải thuật và Lập trình - Lê Minh Hoàng.

Website: GeeksforGeeks - mục "KMP Algorithm for Pattern Searching".